Указатель заглавий произведений художественной литературы, 1801–1975

Кирилл Маслинский, Евгения Лекаревич

Аннотация

В датасете в машиночитаемом виде представлены тома «Указателя заглавий произведений художественной литературы, 1801–1975». Печатный указатель предназначен для определения имени автора по заглавию художественного произведения. В нем представлены художественные произведения, изданные в виде отдельных книг, на русском языке и в переводах с иностранных языков и языков народов СССР с 1801 по 1975 год. Включены издания «вольной печати» и зарубежных издательств, сотрудничавших с РСФСР в 1920-е гг. Для удобства пользователей записи из указателей были разделены на отдельные поля (автор, заглавие, альтернативное заглавие) с помощью автоматического анализатора. Данные представлены в табличной форме.

Формат цитирования датасета: *Маслинский, Кирилл; Лекаревич, Евгения* Указатель заглавий произведений художественной литературы, 1801–1975 // Репозиторий открытых данных по русской литературе и фольклору. 2026. V1. https://doi.org/10.31860/openlit-2022.12-B012

Общее описание данных

Машиночитаемая библиографическая база данных отражает заглавия всех видов, родов и жанров художественной литературы. Базируется на семитомном «Указателе заглавий произведений художественной литературы». В указателе представлены книги, написанные на русском языке, и издания переводов с иностранных языков и языков народов СССР. По оценке составителей, в «Указатель» включено около 130000 заглавий художественных произведений, опубликованных в виде отдельных книг на территории дореволюционной России и СССР (в том числе издания «вольной русской печати», а также зарубежных издательств, сотрудничавших с РСФСР в 1920-е гг.). Фактически в шести томах указателя около 104 тыс. пронумерованных записей (см. «Сводка»). Для удобства пользователей записи из указателей были разделены на отдельные поля (автор, заглавие, альтернативное заглавие) с помощью автоматического анализатора. Данные представлены в табличной форме.

«Алфавитный указатель заглавий художественных произведений» выделяет из потока книг, вышедших в дореволюционной России и СССР, произведения *художественной* литературы, включая иностранные сочинения, переводившиеся на русский язык в течение 175 лет. Работа над этим изданием велась коллективами специалистов из Государственной библиотеки СССР им. В. И. Ленина, Государственной публичной библиотеки имени М. Е. Салтыкова-Щедрина и Библиотеки Академии наук СССР, начиная с 7 тома — РГБ, РНБ, БАН, основой для составления «Указателя» послужили генеральные алфавитные каталоги этих библиотек. С критериями отбора произведений для указателя можно ознакомиться в предисловии от составителей к первому тому (с. 7–10). В настоящем датасете представлены шесть томов указателя, охватывающие период 1801–1975 гг. Седьмой том, содержащий указатель всех авторов, упомянутых в первых шести томах, не проходил преобразования в табличный формат и включен в настоящий датасет только в виде текстового файла (OCR).

Указатель заглавий произведений художественной литературы, 1801–1975 : [в 8 т.] / Гос. б-ка СССР им. В.И. Ленина, Гос. публ. б-ка им. М. Е. Салтыкова-Щедрина, Б-ка Акад. наук СССР ; сост.: Б. М. Вишневецкая, А. А. Колганова … Е. К. Соколинский [и др.]. – Москва, 1985–1995.

- Т. 1 : А-Г. – 1985. – 488 с.
- Т. 2 : Д-З. – 1986. – 349 с.
- Т. 3 : И-Л. – 1989. – 326 с.
- Т. 4 : М-О. – 1990. – 431 с.
- Т. 5 : П-С. – 1990. – 477 с.
- Т. 6 : С(Сел.) - Я. – 1991. – 544 с.
- Т. 7 : [Указатели] / Рос. гос. б-ка, Рос. нац. б-ка, Б-ка Акад. наук Рос. Федерации. – 1995. – 536 с.

Данные были получены в результате автоматизированного парсинга отсканированных указателей. Работа велась итеративно: по результатам парсинга проводилась проверка и правка ошибок в исходных текстовых файлах указателей, корректировка алгоритмов парсера и запуск парсера по откорректированным данным. Все исправления вносятся в исходные текстовые файлы или в код парсера, таблицы данных целиком порождаются парсером. Массовые исправления (переносы, ошибочно распознанные символы, разрывы в именах авторов) выполнены сценариями из каталога `scripts/` с использованием указателя имен авторов (т. 7) для проверки написания фамилий; ручные исправления, сверенные с отсканированными версиями томов указателя, сгруппированы в истории изменений репозитория по видам ошибок.

Текущая версия всех исходных файлов и код, на основании которых составлена база, находится в гит-репозитории по адресу: https://github.com/maslinych/fiction-titles. Авторы датасета будут признательны за сообщения о замеченных ошибках и неточностях. Для связи можно воспользоваться контактами, указанными в метаданных

датасета. По мере исправления ошибок и дополнения данных будут публиковаться новые версии датасета.

Состав датасета

- `csv/vol_1.csv ... csv/vol_6.csv` — списки заглавий произведений (по одному файлу на том указателя).
- `txt/vol_1.txt ... txt/vol_6.txt` — распознанные (OCR) и исправленные тексты шести томов указателя, из которых парсером порождаются таблицы `csv/vol_N.csv`.
- `txt/vol_7.txt` — распознанный (OCR) текст седьмого тома (указатель имен авторов); в табличный формат не преобразовывался.
- `scripts/split_records.py` — парсер, разбивающий текст тома на записи и поля.
- `scripts/stats.py` — сценарий, порождающий сводную таблицу (см. ниже).
- `Makefile` — правила для запуска парсера и сценария сводки.
- `datapackage.json` — формальное описание датасета по стандарту Frictionless Data Package v2: состав файлов, структура таблиц, типы и описания полей.
- `tests/` — тесты целостности данных: проверяют соответствие таблиц описанию в `datapackage.json` (см. `tests/tests_readme.md`).
- `README.md` — этот файл.

Для воспроизведения парсинга нужны Python 3 и модуль `regex` (`pip install regex`), а также утилита `make`. Структура каталогов датасета должна быть сохранена. Команда `make split` заново порождает все файлы `csv/vol_N.csv` из `txt/vol_N.txt`; отдельный том можно обработать командой `make csv/vol_3.csv` или напрямую: `python3 scripts/split_records.py txt/vol_3.txt csv/vol_3.csv`. Команда `make stats` выводит сводную таблицу. Тесты запускаются командой `python3 -m pytest tests` (нужны пакеты из `tests/requirements.txt`).

В датасет входят только перечисленные выше файлы. Отсканированные тома указателя (PDF) и сценарии массового исправления исходных текстов (`scripts/fix_*.py`, `scripts/txt_rules.py`, `scripts/remove_ocr_junk.py` и др.) в датасет не входят; они находятся в гит-репозитории проекта (см. выше).

Сводка

Файл	Буквы	Записей	alt_title	in	note	Непустой tail	MISSING
vol_1.csv	А–Г	19043	592	334	9	72 (0.4%)	0

Файл	Буквы	Записей	alt_title	in	note	Непустой tail	MISSING
vol_2.csv	Д–З	13249	389	184	11	29 (0.2%)	0
vol_3.csv	И–Л	12475	361	296	10	44 (0.4%)	0
vol_4.csv	М–О	17013	458	420	18	32 (0.2%)	0
vol_5.csv	П–С (Сек.)	19146	591	397	12	36 (0.2%)	0
vol_6.csv	С (Сел.)–Я, A–Z	22889	630	490	11	96 (0.4%)	1
Всего		**103815**	3021	2121	71	309 (0.3%)	1

Для каждого файла указаны число записей и число записей с непустыми полями `alt_title`, `in`, `note` и `tail`, а также число пропущенных номеров (`MISSING`). Таблица порождается командой `make stats` (сценарий `scripts/stats.py`).

Формат данных

vol_N.csv

Колонки в таблице данных:

- `start` — номер строки в исходном txt-файле (`txt/vol_N.txt`), на которой начинается запись.
- `end` — номер строки в исходном txt-файле, на которой оканчивается запись (включая следующие за записью пустые строки).
- `num` — порядковый номер записи, как в источнике. Некоторые номера повторяются и могут быть снабжены буквенными индексами (1б), другие пропущены, в этих случаях вместо одного номера записи указан диапазон (101—102). Если номер пропущен в самом источнике, в таблице есть строка с этим номером, где `title` = `NOPARSE` и `tail` = `MISSING` (единственный случай — т. 6, № 19080). У такой строки `start` равен номеру строки, с которой начинается следующая запись, а `end` = `start` − 1: запись-заполнитель не занимает ни одной строки txt-файла и лишь отмечает место пропуска.
- `title` — заглавие произведения, включая подзаголовок (отделен двоеточием). Запись т. 5, № 3859 повреждена в самом источнике: вместо заглавия и фамилии автора напечатано только «борис Исаакович.»; этот текст оставлен в `title` с пометой «[sic!]».
- `author` — автор(ы) издания. Формат указания автора — как в источнике: фамилии авторов выделены заглавными буквами, раскрытие псевдонима дано в скобках; написание имен (в том числе «ё» и строчные или прописные частицы «де», «фон» и т. п.) не унифицировалось, поэтому одно и то же лицо может быть записано по-разному (например, «ФЕДОРОВ» и «ФЁДОРОВ»). Точка, завершающая библиографи-

ческую запись, в конце значения снята; точка сохраняется, если она закрывает инициал или сокращенное имя («ЗОНЕНБЕРГ, Х.», «АЛТАЕВ, Ал.»). Если автор не установлен, указано «Имя авт. не установлено»; у нескольких записей, где в источнике нет сведений об авторе, поле пустое.

- `alt_title` — альтернативные названия, под которыми издавалось произведение (пометы «Изд. также под загл.:», «На тит. л. загл.:», «Загл. обл.:»). Если таких названий несколько (помета «Изд. также под заглавиями:»), они перечислены через «; », как в источнике. Поле не разбито на список, потому что «; » встречается и внутри самих заглавий.
- `in` — заглавие издания, в составе которого напечатано произведение (помета «В кн.:»).
- `note` — примечания об атрибуции: «Ошибочно приписывалось...», «Предполагаемое имя авт.: ...».
- `tail` — фрагмент записи, который не удалось автоматически распределить по остальным колонкам. Здесь могут отражаться ошибки распознавания либо нестандартные пометы, использованные в Указателе (например, «1-я пьеса изд. также под загл.: ...»).

Использование AI при подготовке датасета

На финальных этапах подгтовки данных использовалась модель Claude Opus 5.5. в агентном режиме (Claude Code) для отладки скрипта парсинга, автоматизированной корректировки ошибок OCR, а также для проверки данных и написания тестов.